

RAPPORT DE PROJET

unica-course-allocation

Réalisé par
**Promo Modélisation par
des contraintes (2025-
2026)**

Encadré par
Arnaud Malapert

Résumé

Ce document constitue un début de rapport pour le projet *unica-course-allocation* consacré à l'affectation des unités d'enseignement (UE) du Master Informatique. Il présente le contexte, les objectifs, les données disponibles et une formalisation mathématique des contraintes du problème. [à compléter avec les éléments que l'on va ajouter]

Table des matières

1	Introduction et problématique	3
1.1	Introduction	3
1.2	Contexte et problématique	3
1.3	Objectifs du projet	3
2	Données	3
2.1	Données disponibles	3
2.2	Format des données	4
2.2.1	Entrée	4
2.2.2	Sortie	4
2.2.3	Contraintes	4
3	Métriques d'évaluations et de comparaisons	5
3.1	Biais de type I	6
3.2	Métriques vectorielles	7
3.3	Reprendre ici avec les distances	9
3.4	Autres métriques vectorielles	9
3.5	Métriques agrégées	10
3.5.1	Métriques agrégées de base	10
3.5.2	Pareto en tant que métrique d'agrégation	13
3.6	Autre indicateurs, les tests d'hypothèses	14
4	Méthodologie et implémentation	15
4.1	Méthode proposée	15
4.2	Implémentation	15
5	Expériences	15
6	Résultats et discussions	16
6.1	Résultats	16
6.2	Discussion	16
7	Conclusion	16

1 Introduction et problématique

1.1 Introduction

Dans le Master Informatique de l'Université Côte d'Azur, les étudiantes et étudiants choisissent chaque semestre un ensemble d'UE à partir d'un catalogue commun aux parcours *Informatique* et *IA*. Le choix est contraint par :

- des capacités limitées par UE,
- des incompatibilités d'emploi du temps,
- des UE obligatoires dépendant du parcours.

Le mécanisme actuel de type « premier arrivé, premier servi » est simple mais peut générer des inégalités importantes. Le projet vise donc à proposer une méthode d'affectation plus *équitable*, tout en restant explicable et opérationnelle.

1.2 Contexte et problématique

Le problème est **multiagent** (plusieurs étudiants avec des préférences différentes) et **multi-critère** (respect des obligations, prise en compte des préférences, équité globale).

Dans ce cadre, il n'existe pas nécessairement une solution unique optimale pour tous les critères simultanément. L'enjeu principal est alors de :

1. définir une notion mesurable d'**équité**,
2. proposer une procédure d'affectation compréhensible,
3. évaluer quantitativement la qualité des affectations obtenues.

1.3 Objectifs du projet

D'après la description du projet, la preuve de concept attendue doit :

- définir le concept d'*affectation équitable* et proposer des indicateurs quantitatifs,
- améliorer le système d'affectation actuel par un processus simple et explicable,
- rester flexible vis-à-vis des paramètres (nombre d'étudiants, d'UE, de parcours, de places, etc.),
- présenter des résultats lisibles, cohérents et scientifiquement argumentés.

2 Données

2.1 Données disponibles

Les données exploitées dans le projet sont :

- la liste des UE obligatoires et optionnelles selon les parcours,
- les capacités d'accueil des UE (hors places réservées aux obligations de parcours),
- les incompatibilités d'emploi du temps entre UE,
- pour chaque étudiant : parcours, nombre maximum d'UE souhaitées, préférences sur les UE.

Notes :

- certaines UE externes au processus principal peuvent être considérées à capacité « illimitée »,
- toute UE non obligatoire dans un parcours est considérée comme optionnelle.

2.2 Format des données

Soit n le nombre d'étudiants, m le nombre d'UE et p le nombre de parcours.

2.2.1 Entrée

— **Unités d'Enseignements :**

- $c_j \in \mathbb{N}$: la capacité de l'UE $j \in \llbracket 1, m \rrbracket$.
- $I_{j,j'}^c \in \{0, 1\}$: la matrice d'incompatibilité des UE $(j, j') \in \llbracket 1, m \rrbracket^2$, où la case (j, j') vaut 1 si les UE sont incompatibles, 0 autrement.

— **Parcours :**

- $mmin_k \in \mathbb{N}^*$: le nombre minimum d'UE optionnelles à suivre dans le parcours $k \in \llbracket 1, p \rrbracket$.
- $m_{j,k} \in \{0, 1\}$: indique si l'UE $j \in \llbracket 1, m \rrbracket$ est obligatoire dans le parcours $k \in \llbracket 1, p \rrbracket$.

— **Étudiants :**

- $mmax_i$: le nombre maximum d'UE souhaité par l'étudiant $i \in \llbracket 1, n \rrbracket$.
- $p_i \in \llbracket 1, p \rrbracket$: le parcours suivi par l'étudiant $i \in \llbracket 1, n \rrbracket$.
- $r_i : \llbracket 1, m \rrbracket \rightarrow \mathbb{R}^+$: une fonction de rang (par les méthode des rangs moyens) indiquant les préférences d'un étudiant i , telle que plusieurs UE peuvent avoir le même rang, que les rangs soient consécutifs, que la somme des rangs soit égale pour tous les étudiants et que le premier rang soit occupé par les UE obligatoires (si applicable).

2.2.2 Sortie

- $A_{i,j}$: une affectation d'UE pour l'étudiant $i \in \llbracket 1, n \rrbracket$; 1 si l'UE $j \in \llbracket 1, m \rrbracket$ est affecté, 0 sinon.

2.2.3 Contraintes

- (C1) « Pour chaque UE, la somme des affectations pour celle-ci ne dépasse pas sa capacité » :

$$\forall j \in \llbracket 1, m \rrbracket : \sum_{i \in \llbracket 1, n \rrbracket} A_{i,j} \leq c_j$$

- (C2) « Une affectation ne peut accorder que des UE compatibles » :

$$\forall (i, j, j') \in \llbracket 1, n \rrbracket \times \llbracket 1, m \rrbracket^2 : I_{j,j'}^c + A_{i,j} + A_{i,j'} \leq 2$$

- (C3) « Un étudiant inscrit dans un parcours p doit se voir attribuer toutes les UE obligatoires du parcours p » :

$$\forall (i, j, k) \in \llbracket 1, n \rrbracket \times \llbracket 1, m \rrbracket \times \llbracket 1, p \rrbracket : A_{i,j} - \mathbf{1}_{p_i=k} - m_{j,k} \geq -1$$

- (C4) « Un étudiant doit recevoir une affectation de 8 à 10 UE » :

$$\forall i \in \llbracket 1, n \rrbracket : 8 \leq \sum_{j \in \llbracket 1, m \rrbracket} A_{i,j} \leq 10$$

- (C5) « Un étudiant peut recevoir au maximum le nombre de UE qu'il a demandé » :

$$\forall i \in \llbracket 1, n \rrbracket : \sum_{j \in \llbracket 1, m \rrbracket} A_{i,j} \leq mmax_i$$

Note. $1_{a=b}$ est la fonction indicatrice définie par 1 si $a = b$ et 0 sinon.

3 Métriques d'évaluations et de comparaisons

Dans le cadre de ce projet, être en mesure d'évaluer et de comparer plusieurs instances d'affectations d'étudiant est important. En effet, sans cela, nous serions bien incapable de mesurer une potentielle amélioration du système, actuellement exploité, mais aussi de vérifier l'existence d'éventuels biais dans les affectations et donc d'établir si une affectation est « équitable ».

Afin de réaliser cet objectif d'évaluation, nous devons développer des métriques et des indicateurs adéquats au problème. Dans ce rapport, nous nous concentrons sur les métriques vectorielles, contenant une valeur pour chaque entité mesuré, mais aussi sur d'autres indicateurs nous permettant d'évaluer les potentiels biais d'une affectation.

Remarque 1. Dans ce document, nous avons concentré les informations les plus importantes, mais un gros travail de réflexion sur les métriques, les éventuelles alternatives et biais induits a été mené. Celui-ci est disponible sous la forme d'une annexe (**Annexe I - Brouillon et Réflexions sur les Métriques**), dont cette partie est un résumé.

Dans la suite de cette section, nous présentons une partie des métriques développées, leurs avantages et leurs défauts. Avant cela, nous devons néanmoins définir plusieurs notions :

Définition 1 (Produit de Schur). Soit X et Y deux matrices de même dimension dans $\mathbb{R}_{n,m}$, nous définissons le produit de Schur $\odot$ comme l'opération qui associe à X et Y la matrice Z tel que $\forall (i, j) \in \llbracket 1, n \rrbracket \times \llbracket 1, m \rrbracket : z_{i,j} = x_{i,j} \cdot y_{i,j}$. Ou plus graphiquement :

$$Z = X \odot Y = \begin{bmatrix} x_{0,0} & \cdots & x_{0,m} \\ \vdots & \ddots & \vdots \\ x_{n,0} & \cdots & x_{n,m} \end{bmatrix} \odot \begin{bmatrix} y_{0,0} & \cdots & y_{0,m} \\ \vdots & \ddots & \vdots \\ y_{n,0} & \cdots & y_{n,m} \end{bmatrix} = \begin{bmatrix} x_{0,0} \cdot y_{0,0} & \cdots & x_{0,m} \cdot y_{0,m} \\ \vdots & \ddots & \vdots \\ x_{n,0} \cdot y_{n,0} & \cdots & x_{n,m} \cdot y_{n,m} \end{bmatrix}$$

Définition 2 (Matrice des rangs d'affectation). Soit $A_{i,j} \in \{0,1\}_{n,m}$ la matrice représentant l'affectation accordée à l'étudiant $i \in \llbracket 1, n \rrbracket$ pour l'UE $j \in \llbracket 1, m \rrbracket$. Soit $R_{i,j} \in \mathbb{R}_{n,m}^+$ la matrice représentant les rangs accordés par l'étudiant $i \in \llbracket 1, n \rrbracket$ pour l'UE $j \in \llbracket 1, m \rrbracket$, nous définissons la matrice des rangs d'affectation $U_{i,j} = A_{i,j} \odot R_{i,j}$ comme la matrice des rangs des UE effectivement affectés à l'étudiant i .

Exemple 1. Dans le cadre de ce rapport, nous allons développer un exemple fictif et l'exploiter tout du long à des fins d'illustrations. Pour cet exemple, nous aurons 5 étudiants : Sophie et Pierre en parcours IA, puis Hugo, Axel et Sabine en parcours Informatique. Il y a 4 UEs : AI, obligatoire en IA, Code, obligatoire en Informatique, Éco et Droit. Chaque cours dispose de 4 places (places réservées incluses). Un étudiant doit choisir entre 2 et 3 UEs. Voici les préférences de chaque étudiants, ainsi que le nombre d'UEs qu'ils souhaitent prendre :

$$R_{i,j} = \begin{bmatrix} \text{UEs} & \text{AI} & \text{Code} & \text{Éco} & \text{Droit} \\ \text{Sophie} & 1 & 2 & 3 & 4 \\ \text{Pierre} & 1 & 2 & 3 & 4 \\ \text{Hugo} & 2 & 1 & 3 & 4 \\ \text{Axel} & 2 & 1 & 4 & 3 \\ \text{Sabine} & 2 & 1 & 3 & 4 \end{bmatrix} \quad m\max_i = \begin{bmatrix} \text{UEs} & m\max_i \\ \text{Sophie} & 2 \\ \text{Pierre} & 3 \\ \text{Hugo} & 3 \\ \text{Axel} & 3 \\ \text{Sabine} & 3 \end{bmatrix}$$

Usant d'une affectation arbitraire, voici les affectations reçus et la matrice des rangs d'affectation

correspondante :

$$A_{i,j} = \begin{bmatrix} \text{UEs} & \text{AI} & \text{Code} & \text{Éco} & \text{Droit} \\ \text{Sophie} & 1 & 1 & 0 & 0 \\ \text{Pierre} & 1 & 0 & 1 & 1 \\ \text{Hugo} & 1 & 1 & 1 & 0 \\ \text{Axel} & 1 & 1 & 0 & 1 \\ \text{Sabine} & 0 & 1 & 1 & 1 \end{bmatrix} \quad U_{i,j} = \begin{bmatrix} \text{UEs} & \text{AI} & \text{Code} & \text{Éco} & \text{Droit} \\ \text{Sophie} & 1 & 2 & 0 & 0 \\ \text{Pierre} & 1 & 0 & 3 & 4 \\ \text{Hugo} & 2 & 1 & 3 & 0 \\ \text{Axel} & 2 & 1 & 0 & 3 \\ \text{Sabine} & 0 & 1 & 3 & 4 \end{bmatrix}$$

Avec celle ci, nous pouvons donc voir que tous les étudiants se sont fait affecté leurs UEs obligatoires et que Sabine et Pierre n'ont pas eu leurs deuxièmes choix. Nous pouvons également observer que les cours AI, et Code sont complets.

Maintenant que nous avons introduit la matrice des rangs d'affectation, nous serons en capacité d'introduire les métriques vectorielles que nous utiliserons dans ce projet. Néanmoins, avant cela, nous devons réfléchir à la nature des données et leurs biais intrinsèques.

3.1 Biais de type I

Dans la majorité des mesures auxquels nous souhaiterions recourir (moyenne, somme, écart-type, etc.), nous observons premièrement que nous travaillerons sur des rangs, qui, par nature, augmentent avec le nombre d'entité classés. De plus, nous observons que chaque étudiant dispose d'une certaine liberté dans le nombre d'UEs qu'il choisit. Malheureusement, bien que cela soit bénéfique pour l'étudiant, cela rend propice l'apparition de biais sur nos futures mesures.

Ainsi, si nous avons un étudiant E_1 choisissant 9 UEs et un autre E_2 en choisissant 7, E_1 se verra octroyer des rangs supplémentaires dans la matrice d'affectation des rangs (pour la huitième et la neuvième UE); or, par nature des rangs, ceux-ci sont plus élevé que le septième rang lui étant été attribué. Des métriques qui pourraient étre intéressantes, comme le dernier rang, la somme/moyenne des rangs ou l'écart-type, se voient donc artificiellement augmentées. E_2 ne se voyant pas attribué un huitième et neuvième rang, celui-ci aura en général des valeurs plus faibles pour les métriques citées que E_1 .

Bien que cette remarque semble innocente, elle pose en réalité un vrai problème, car elle s'étend aux optimisations que nous chercherons à faire pour obtenir la «meilleure» affectation possible. En effet, nous cherchons généralement à minimiser une métrique sur les rangs; ainsi, E_1 ayant pour cette métrique une valeur plus élevé se verra probablement priorisé par rapport à E_2 et ce même si celui-ci pourrait avoir une moins bonne affectation en général. Nous désignerons ce biais comme un biais de «**Type I**» (un biais de Type II existe également sur des instances particulières, voir Annexe I pour plus d'information). Pour réduire ce biais au plus possible, nous allons tout d'abord devoir mieux préciser la nature des UEs.

Définition 3. Soit $\text{aSet}(i) = \arg_j \{ \mathbf{1}_{A_{i,j}=1} \}$, l'ensemble, ordonné par rangs, des UEs affectés à un étudiant $i \in \llbracket 1, n \rrbracket$, nous pouvons distinguer trois types d'UEs : les UEs obligatoires pour l'étudiant en raison du parcours que l'on notera $\text{mSet}(i)$, celles optionnelles permettant d'atteindre le quota minimum d'UE pour passer le semestre $\text{oSet}(i)$ et les UEs facultatives définis par $\text{fSet}(i) = \text{aSet}(i) \setminus [\text{mSet}(i) \cup \text{oSet}(i)]$. Attention, les trois ensembles sont disjoints.

Étant donné que le nombre minimum d'UE requis pour passer le semestre pour chaque étudiant peut être obtenu par $m_{\min}(i) = \#\text{oSet}(i) + m\min_{p_i} \forall i \in \llbracket 1, n \rrbracket$, nous pouvons montrer que le nombre d'UE minimum pour passer le semestre $m_{\min}(i)$ est constant pour tous les étudiants d'un même parcours. En pratique, nous pourrions émettre l'hypothèse que ce nombre d'UE est égal peu importe les parcours.

Exemple 2. En se basant sur l'exemple 1, nous reprenons nos étudiants : Sophie, Pierre, Hugo, Axel et Sabine. Voici l'ensemble ordonnées des affectations, des affectations obligatoires, optionnelles et facultatives pour chacun d'entre eux :

Étudiant	Sophie	Pierre	Hugo	Axel	Sabine
$aSet(i)$	$\{AI, Code\}$	$\{AI, Éco, Droit\}$	$\{Code, AI, Éco\}$	$\{Code, AI, Droit\}$	$\{Code, Éco, Droit\}$
$mSet(i)$	$\{AI\}$	$\{AI\}$	$\{Code\}$	$\{Code\}$	$\{Code\}$
$oSet(i)$	$\{Code\}$	$\{Éco\}$	$\{AI\}$	$\{AI\}$	$\{Éco\}$
$fSet(i)$	$\emptyset$	$\{Droit\}$	$\{Éco\}$	$\{Droit\}$	$\{Droit\}$

Ici, nous pouvons, en quelques sortes, voir la nature de « tiroir » de ces catégories, nous remplissons en effet d'abord l'ensemble des UEs obligatoires, puis des UEs optionnelles et enfin des UEs facultatives s'il y en a.

Dans notre cadre, où nous émettons l'hypothèse que le nombre d'UE dans l'union de $mSet$ et de $oSet$ est identique pour chaque étudiant et parcours (il s'agit bien de notre cas dans notre Master, mais attention, ce n'est pas forcément le cas dans le cadre général), alors nous disposons maintenant d'une borne fixe sur le nombre d'UE plutôt que d'une borne variant selon le désir des étudiants. Ainsi, les étudiants étant placés à la même enseigne, le biais de Type I ne fait plus effet si nous calculons nos métrique sur l'ensemble des affectations non facultatives.

À noter néanmoins que cela a une implication forte : **Les UEs facultatives sont moins importantes que les UEs non facultatives**. De ce fait, nous pouvons nous permettre une moins bonne affectations pour les UEs facultatives, pour lequel l'étudiant pourra l'abandonner sans conséquences, si cela nous permet d'avoir une meilleur affectation des UEs obligatoires et optionnelles que l'étudiant ne pourra pas abandonner s'il veut passer son semestre.

Maintenant que cela est dit, nous pouvons enfin passer à nos métriques vectorielles.

3.2 Métriques vectorielles

Métrique (Dernier rang non facultatif affecté). Définit pour les étudiants uniquement, le dernier rang non facultatif affecté correspond pour chaque étudiant i au rang maximum des $m_{\min}(i)$ UEs au rang le plus faible. Elle se formalise ainsi :

$$\forall i \in \llbracket 1, n \rrbracket : \text{lastMandatoryRank}(i) = \max_{j \in mSet(i) \cup oSet(i)} U_{i,j}$$

En prenant le dernier rangs des UEs requises pour passer le semestre, cette métrique fait la promesse d'être intuitive, compréhensible et simple à calculer tout en nous donnant une borne supérieure sur les rangs affectés (ce qui peut être utile à des fins de minimisations). Malheureusement, celle-ci ne capture pas la distribution des rangs affectés inférieurs. En d'autre termes, un étudiant peut se voir affecter un dernier rang élevé, mais n'avoir que des UEs de rangs faibles pour ces autres affectations; à l'inverse, un étudiant peut aussi avoir un dernier rang affecté moyen, mais avoir ces autres affectations très concentrées autours de cette borne, rendant ainsi l'affectation non satisfaisante pour l'étudiant. Nous devons donc trouver une autre métrique permettant de prendre en compte cette distribution, même ne serait-ce qu'implicitement.

Métrique (Somme des rangs non facultatifs). Définit pour les étudiants, la somme des rangs non facultatifs est la métrique sommant les rangs de l'ensemble des UEs non facultatives affectés pour chaque étudiant. Elle se formalise ainsi :

$$\forall i \in \llbracket 1, n \rrbracket : \text{correctedRankSum}(i) = \text{rankSum}(i) - \sum_{j \in fSet(i)} U_{i,j}$$

Cette métrique à plusieurs avantages. Premièrement, elle dispose d'une interprétabilité simple : plus la valeur est élevé, plus l'étudiant est lésé ; plus la valeur faible, meilleur la satisfaction de l'étudiant. Deuxièmement, la métrique est rapide, simple à calculer et permet de prendre en compte la distribution sous-jacente des rangs non-facultatifs affectés de manière implicite. Enfin, elle reste intuitive, simple à accepter, à comprendre et à expliquer ; cela rendant ainsi le système plus abordable pour les exploitants.

Exemple 3. Dans la continuité des exemples précédents, nous allons maintenant calculer les métriques cités plus hauts sur nos étudiants :

Étudiant	Sophie	Pierre	Hugo	Axel	Sabine
$lastMandatoryRank(i)$	2	3	2	2	3
$correctedRankSum(i)$	3	4	3	3	4

Ici, nous observons bien que les dernières UEs affectés n'ont pas eu d'impacts sur la sommes des rangs non facultatifs ou le dernier rang non facultatif. Cela rends dans notre cas des valeurs similaires pour chacun des étudiants, ce qui est une bonne chose en constituant une première piste pour la notion d'équité que nous n'avons toujours pas défini formellement. Aussi, nous pouvons bien mesurer l'intérêt de prendre ces métriques corrigés du biais de Type I au lieu de prendre leurs consœurs non corrigés. Ainsi, dans cette exemple, Sophie aurait toujours eu une somme de 3, tandis que Hugo aurait eu une somme de 6 alors que leur affectation regardant les UEs non facultatives sont sensiblement identique.

À partir de là, il peut également être intéressant d'établir une moyenne et un écart-type afin de mieux comprendre la distributions des rangs non-facultatifs affectés ; néanmoins, cela alourdirais beaucoup trop l'analyse des affectations pour l'opérateur (si l'on considère que la somme et la moyenne sont les mêmes choses à une constante multiplicative près). Malgré tous, cela étant intéressant d'un point de vue statistiques, celles-ci sont implémentés au côté d'autres métriques (voir Annexe I pour plus de détails).

Les métriques cités plus hauts sont directement utilisables dans un solveur linéaire, mais il existe aussi des métriques non-linéaires qui peuvent être intéressantes pour leurs interprétations, c'est ce que nous allons voir maintenant.

Définition 4. Soit X une variable aléatoire et $x \in]0, 1[$. Le quantile d'ordre x de la distribution de X , noté Q_x , est défini par : $Q_x = \min\{y \in \mathbb{R} : \mathbb{P}[X \leq y] \geq x\}$. Ainsi, le premier quartile $Q_1 \equiv Q_{0.25}$, correspond à la valeur y tel que 25% de la population est en dessous de y . De même, la médiane (ou deuxième quartile) $Q_2 \equiv Q_{0.5}$ correspond à la valeur y tel que la moitié de la population se trouve en dessous de cette valeur. Enfin, le troisième quartile $Q_3 \equiv Q_{0.75}$ équivaut à la valeur y tel que les trois quarts de la population se trouve en de dessous de y .

Métrique (Médianes et Quartiles des rangs non-facultatifs affectés). Définit pour les étudiants, le premier, deuxième et troisième quartiles des rangs non-facultatifs affectés sont formalisés ainsi (par abus de langage) :

$$\forall i \in \llbracket 1, n \rrbracket : Q_{0.25|0.5|0.75}(i) = \min\{y : \mathbb{P}[aSet(i) \setminus fSet(i) \leq y] \geq 0.25|0.5|0.75\}$$

Bien que non linéaires et plus compliquées à calculer que la moyenne (en pratique, il y a souvent une fonction pour les calculer simplement), cette famille de métrique offre de nombreux avantages. En effet, elle permet de disposer d'une mesure de centralité résistante à de potentielles valeurs extrêmes (voir biais de Type II, Annexe I), d'une interprétation intéressante, tout particulièrement la médiane qui permet de séparer 50% de la population, mais aussi de prendre en compte la distribution sous-jacente via l'analyse des quantiles. Par exemple si Q_1 est élevé (par

rapport au rang minimum), nous savons d'or et déjà que la distribution est étalé sur la gauche (ce qui est une mauvaise chose). De même si Q_3 est faible nous observons que la distribution est étalé sur la droite (ce qui est une bonne chose).

Dans les faits, nous n'irons généralement pas aussi loin et resterons sur l'interprétation de la médiane uniquement.

À noter que comme pour la moyenne, la médiane possède une mesure de dispersion au doux nom d'Écart Interquartile ($IQR(i) = Q_3(i) - Q_1(i)$). Contrairement à l'écart-type, celui-ci dispose d'une interprétation naturelle en explicitant la dispersion des 50% de la population autours de la médiane. Il s'agit donc pour cette raison que nous le mentionnons tout de même.

Exemple 4. *Encore une fois, comme pour l'exemple 3, nous allons calculer les nouvelles métriques pour nos étudiants*

Étudiant	Sophie	Pierre	Hugo	Axel	Sabine
$Q_2(i)$	1.5	2	1.5	1.5	2
$IQR(i)$	1	2	1	1	2

Dans notre petit exemple, les notions de médiane et d'IQR perdent un peu leurs sens, surtout en considérant que pour atteindre les quantiles désirés via Python ou autre, une correction de continuité est généralement faite. Malgré tout, nous pouvons quand même dire à partir de ces données qui a eu la moins bonne affectation : Pierre et Sabine. En effet, ces derniers ont eu la plus forte médiane 50% des UEs attribués ont un rang au dessus de 2 et un IQR élevé (dans ce contexte) à 2, c'est à dire que les rangs sont plus dispersés que pour les autres étudiants. Dans l'idéal, nous cherchons une médiane et un IQR sur les rangs non-facultatifs faible.

3.3 Reprendre ici avec les distances

3.4 Autres métriques vectorielles

Dans certains cas, il peut être intéressant de compléter les métriques précédemment introduites avec d'autres métriques utiles dans le cadre d'évaluation d'affectation (les métriques introduites dans cette section sont pour la plupart inutilisable à des fins d'affectation).

Premièrement, dans le cadre d'une UE, il peut être intéressant de calculer le nombre de places affectées et non affectées. En effet, cela permet d'avoir un aperçu de la charge d'une affectation sur chacun des UEs. De la même idée, nous pouvons aussi nous inspirer du problème d'équilibrage des charges afin d'introduire une métrique permettant de calculer la différence à une affectation équilibré des étudiants aux UEs.

Lemme 1 (Borne minimum pour l'équilibrage des affectations). Soit n le nombre d'étudiant et m le nombre d'UE. Toutes les affectations $A_{i,j}$ vérifies :

$$\frac{m_{\min}n}{m} \leq \frac{\sum_{i=1}^n \#aSet(i)}{m}$$

où $m_{\min}$ correspond au nombre d'UE minimum que doit prendre un étudiant (en supposant que le nombre est identique pour tous les étudiants). En d'autres mots, la moyenne du nombre d'étudiant affecté par UE est supérieur ou égale au nombre minimum d'UE à prendre pour chaque étudiant diviser par le nombre de cours.

Métrique (Équilibre des affectations aux UEs). À partir du lemme précédent, nous pouvons définir l'équilibre des affectations aux UEs comme la différence entre le nombre d'affectations

réels et la borne minimum sur la moyenne, ou plus formellement :

$$\forall j \in \llbracket 1, m \rrbracket : \text{loadDifference}(j) = \sum_{i=1}^n A_{i,j} - \frac{m_{\min} n}{m}$$

Cette métrique peut être utile dans le cas où nous cherchons à savoir quelles UEs sont les plus/moins chargées par rapport à une affectation uniforme. Cependant, cette métrique possède deux limites majeures ; premièrement, elle suppose que le nombre d'UEs minimum par étudiant est égal peu importe le parcours (dans notre cas, il s'agit bien du cas, mais ça pourrait être autrement), deuxièmement, nous supposons que les UEs n'ont pas de capacités limites et que celles-ci soient égales (ce qui n'est pas le cas). Ainsi, bien qu'intéressante, cette métrique nécessite d'être utilisée avec le nombre de place de chaque UEs pour avoir une interprétation correcte. Notez aussi que la valeur de cette métrique peut être négative (une UE est moins chargé) ou positive (une UE est plus chargé) ; calculer la valeur absolue de celle-ci revient à calculer la distance à la moyenne minimum.

Du côté des étudiant, d'autres métriques peuvent se formuler sur une notion de distance. Ainsi, nous pouvons essayer de mesurer la distance entre une affectation donné et la pire affectation donné.

Métrique. Pour mesurer la distance la distance d'une affectation à la pire possible, nous avons deux paramètres : quelle est la distance à la meilleur et quelle est la distance à la pire. Nous pouvons calculer cela en deux métriques :

$$\forall i \in \llbracket 1, n \rrbracket : \text{maxRankDistance}(i) = \max_{j \in \llbracket 1, m \rrbracket} \{R_{i,j}\} - \text{lastRank}(i) \quad (\text{Au pire})$$

$$\forall i \in \llbracket 1, n \rrbracket : \text{maxRankDistance}(i) = \min_{j \in \llbracket 1, m \rrbracket} \{U_{i,j}\} - \min_{j \in \llbracket 1, m \rrbracket} \{R_{i,j}\} \quad (\text{Au meilleur})$$

Avec ces métriques, nous nous intéressons non seulement au dernier rang affecté en le comparant au dernier rang qui aurait pu être affecté, une distance élevée étant appréciable (on s'éloigne du pire cas) ; mais aussi au premier rang effectivement affecté en le comparant au premier rang qui aurait pu être affecté, une distance faible étant préférable (on s'approche du meilleur cas). Cette métrique peut être intéressante pour vérifier que chaque étudiant a, à défaut d'avoir le meilleur cas, une affectation éloignée du pire cas ou inversement. À noter que dans le cas de la distance au pire cas, le biais de type I peut avoir un impact, nous pouvons donc la corriger de manière similaire aux autres métriques pour limiter ce problème.

Maintenant que nous avons vu les métriques vectorielles, il peut être intéressant de les agréger afin d'obtenir une unique métrique sur laquelle travailler.

3.5 Métriques agrégées

Dans cette section, nous cherchons à concevoir des métriques agrégées, c'est à dire une métrique étant capable de résumer l'entièreté de l'affectation en un seul scalaire. Cela peut se faire de deux façons. Soit nous pouvons résumer les métriques vectorielles, cela nous donne une métrique agrégée pour chaque métriques vectorielles (nous les désignons ci-après par « métriques agrégées de base »). Soit, nous nous basons sur l'ensemble des affectations directement.

3.5.1 Métriques agrégées de base

Dans cette partie, nous ne verrons pas de métriques issues de fonctions d'agrégation que l'on pourrait qualifier « d'exotique » ; en effet, nous chercherons ici à avoir des métrique d'évaluations

ou de comparaison (pas forcément taillées pour l'optimisation). Pour cette raison, nous souhaitons proposer des métriques simplement interprétables et applicable aussi bien aux étudiants qu'aux UEs. À partir de là, la meilleure façon de les représenter est le tableau à double entrées suivant :

Table 1: Métriques d'agrégations pour chaque métrique vectorielle

Métriques/Agrégations	$\mathbb{E}$	σ	γ_1	γ_2	Min	Max	$Q_{0.05} \rightarrow Q_{0.95}$	IQR	C_y	Gini
rankSum	UEs et Étudiants									
rankAvg										
rank σ^2										
rank σ										
Q1										
Q2										
Q3										
IQR										
firstRank										
lastRank										
spots	UEs									
freeSpots										
loadDifference										
minRequestedRank	Étudiants									
maxRequestedRank										
mmax _i										
corRankSum										
corLastRank										
corRank σ^2										
corRank σ										
corQ1										
corQ2										
corQ3										
corIQR										
Nb d'UE en moins										
minRankDist										
maxRankDist										
corMaxRankDist										

Dans ce tableau, les fonctions d'agrégations ont été désignés par leur symboles pour pouvoir l'afficher complètement sur la page. Ainsi $\mathbb{E}$ est la moyenne, σ l'écart-type, γ_1 le coefficient d'asymétrie de Fisher (Skewness), γ_2 le Kurtosis et C_y le coefficient d'asymétrie de Yule. Il a aussi

été introduit quelques métriques vectorielles non définies précédemment : « *spots* » correspondant au nombre de places d'une UE (donnée du problème), « *min/maxRequestedRank* » correspondant au rang minimum attribué et le rang maximum attribué par l'étudiant aux UEs (dépend des égalités) et le « Nombre d'UE » en moins qui indique combien manque-t-il d'UEs facultatives afin d'atteindre le nombre d'UE demandé par l'étudiant.

Concernant les métriques d'agrégations, nous n'allons pas détailler les plus simples (Moyenne, Écart-Type, Min, Max, Quantiles et IQR) que nous avons déjà défini vectoriellement, mais seulement les nouvelles métriques (Coefficient d'Asymétrie de Fisher, Kurtosis, Coefficient d'Asymétrie de Yule, Coefficient de Gini). Commençons par le coefficient d'asymétrie de Fisher et le Kurtosis :

Métrique (Skewness). Soit m_v une métrique vectorielle numérique quelconque de longueur $\#m_v$. Soit σ_v l'écart type calculé sur m_v . Nous définissons le coefficient d'asymétrie de Fisher ou Skewness ainsi :

$$\forall v : \gamma_1(m_v) = \frac{\frac{\sum_{i=1}^{\#m_v} (m_{v_i} - \bar{m}_v)^3}{\#m_v}}{\sigma_v^3}$$

où $\bar{m}_v$ est la moyenne de la métrique vectorielle désignée. Quant-à son interprétation, le coefficient de Fisher est une mesure d'asymétrie et permet donc de dire si une distribution « s'étale » sur la gauche ou sur la droite. Ainsi, si $\gamma_1 \approx 0$, la distribution est symétrique et le mode, la moyenne et la médiane sont similaires. Si $\gamma_1 < 0$, on dit que la distribution est étalée sur la gauche (les valeurs se concentrent à droite) ; il s'agit donc du cas que nous voulons éviter sur les métriques telle que la somme des rangs, la moyenne, etc. (cela indiquerait une mauvaise affectation). Enfin, si $\gamma_1 > 0$, alors la distribution est « étalé sur la droite » (les valeurs se concentrent à gauche) et peu d'étudiants se voient attribué d'affectation moins bonne que la majorité (attention, $\gamma_1 > 0$ n'indique pas forcément une bonne affectation, nous pouvons être dans le cas tous mauvais et une affectation très mauvaise). Cette métrique (comme le Kurtosis que nous allons voir) à néanmoins le défaut d'être très sensible aux valeurs extrêmes, il faut donc faire attention à l'interpréter sur les métriques corrigés du biais de Type I (voire de Type II).

Métrique (Kurtosis). Soit m_v une métrique vectorielle numérique quelconque de longueur $\#m_v$. Soit σ_v l'écart type calculé sur m_v . Nous définissons le coefficient d'aplatissement de Fisher ou Kurtosis ainsi :

$$\forall v : \gamma_2(m_v) = \frac{\frac{\sum_{i=1}^{\#m_v} (m_{v_i} - \bar{m}_v)^4}{\#m_v}}{\sigma_v^4}$$

où $\bar{m}_v$ est la moyenne de la métrique vectorielle désignée. Pour l'interprétation du Kurtosis, il s'agit d'un indicateur « d'aplatissement » ; avec celui-ci, nous cherchons à observer la fréquence d'apparition de valeurs très extrêmes dans une distribution. Malheureusement, cette métrique peut être non intuitive à interpréter et devrait donc être utilisé à des fins d'analyses plus poussées ou avec d'autres métriques. Par exemple, nous savons que si $\gamma_1 \approx 0 \wedge \gamma_2 \approx 3$, alors nous pouvons émettre l'hypothèse que nous sommes en présence d'une loi normale. Pour une idée de l'interprétation de cette métrique, si $\gamma_2 > 3$, alors nous avons plus de valeurs extrêmes que sur une loi normale centrée réduite, si $\gamma_2 < 3$, nous en avons moins et autrement nous en avons en quantité similaire.

Comme vu précédemment, le coefficient d'asymétrie de Fisher (et le Kurtosis) sont très sensibles aux valeurs extrêmes (à cause des puissances), il pourrait donc être intéressant d'avoir au moins un coefficient d'asymétrie non sensible aux valeurs extrêmes.

Métrique (Coefficient d'asymétrie de Yule). Soit m_v une métrique vectorielle numérique quelconque de longueur $\#m_v$. Soit $Q_x(m_v)$ le quantile d'ordre x calculé sur m_v . Nous définissons le coefficient d'asymétrie de Yule ainsi :

$$\forall v : C_y(m_v) = \frac{Q_{0.75}(m_v) + Q_{0.25}(m_v) - 2Q_{0.5}(m_v)}{IQR(m_v)}$$

où $IQR(m_v)$ est l'écart interquartile calculé sur le vecteur. Ce coefficient d'asymétrie $C_y \in [-1, 1]$ est, comme dit précédemment, robuste aux valeurs extrême, mais aussi assez simple à interpréter. Ainsi, si $C_y \approx 0$, alors la distribution est symétrique, si $C_y < 0$ nous pouvons dire que la distribution est « étalé à gauche » (ce qui est une mauvaise chose pour la plupart de nos métriques, car cela voudrait dire des valeurs potentiellement élevées pour le rang). Enfin si $C_y > 0$, alors la distribution est étalé à droite (ce qui est généralement une bonne chose dans la majorité de nos métriques). L'interprétation est donc similaire à celle du coefficient de Fisher, mais cette fois ci sur la médiane.

Il ne nous reste donc plus qu'une métrique agrégé de base à discuter : le coefficient de Gini.

Métrique (Coefficient de Gini). Soit m_v une métrique vectorielle numérique quelconque de longueur $\#m_v$. Soit $\bar{m}_v$ la moyenne calculée sur m_v , nous définissons le coefficient de Gini ainsi :

$$\text{Gini}(m_v) = \frac{\sum_{i=1}^{\#m_v} \sum_{j=1}^{\#m_v} |x_i - x_j|}{2 [\#m_v]^2 \bar{m}_v}$$

Cet indice, très utilisé pour les comparaison d'inégalité des richesses, peut être utilisé dans un cas général de mesure d'inégalité incluant notre application. L'interprétation est cette fois très simple : si le coefficient approche de 0, alors toutes les valeurs de la métrique vectorielle donnée sont identiques ; autrement, dans le cas, où l'indice s'approche de 1, alors nous pouvons interpréter que un individu possède l'intégralité des richesses et les autres rien. Attention tous de même, dans notre cadre, nous cherchons à avoir un coefficient de Gini proche de 0 (sur les métriques tel que la somme des rangs par exemple), non pas parce qu'un coefficient de 1 indiquerait qu'un individu est grandement bénéficiaire du système au détriment des autres, mais plutôt que si un tel individu existait, alors il serait certainement le plus lésé. En d'autres mots, si le coefficient de Gini est proche de 1 sur une métrique telle que la somme des rangs, alors la personne concentrant les « richesses » serait en réalité une personne dont l'affectation est sciemment mauvaise afin de faire bénéficier le reste du groupe de son sacrifice.

Maintenant que nous avons vu ces métriques agrégées de « base », voyons si nous pouvons établir une métrique d'agrégation se basant sur un autre système.

3.5.2 Pareto en tant que métrique d'agrégation

Dans notre situation, où nous cherchons à offrir une affectation à chaque étudiant, plusieurs solutions plus ou moins bonne existent parallèlement. Parfois, nous pouvons passer d'une solution à une autre en échangeant l'affectation d'un étudiant avec celle d'un autre.

Définition 5 (Échange technique). Soit deux étudiants différents $(i_a, i_b) \in \llbracket 1, n \rrbracket_{a \neq b}^2$ où n est le nombre d'étudiant. Nous définissons un « échange technique » comme un échange des affectations de i_a et de i_b , tel que la contraintes des UEs obligatoires est respectée, plus formellement : $\text{mSet}(i_a) \subseteq \text{aSet}(i_b) \wedge \text{mSet}(i_b) \subseteq \text{aSet}(i_a)$ et que le nombre d'UE demandé par chacun des étudiants ne soit pas dépassé $\text{mmax}_{i_a} \geq \#\text{aSet}(i_b) \wedge \text{mmax}_{i_b} \geq \#\text{aSet}(i_a)$. On notera le prédicat $i_a \xrightarrow{T} i_b$ valant 0 s'il n'existe pas d'échange technique entre le couple (i_a, i_b) et 1 autrement.

Bien que la définition d'échange technique permet de s'assurer qu'un échange d'affectation soit techniquement faisable, il ne nous permet pas de dire si un étudiant est bénéficiaire ou lésé par celui-ci. À partir de cette observation, nous pouvons nous rappeler la définition l'utilité de Pareto.

Définition 6 (Échange de Pareto). Soit deux étudiants différents $(i_a, i_b) \in \llbracket 1, n \rrbracket_{a \neq b}^2$ et une métrique vectorielle m_v . Nous définissons un échange de Pareto comme un échange technique tel que si l'échange est opérant, alors $m_{v_{i_a \rightarrow b}} \geq m_{v_{i_a}}$ (resp. $\leq$) et $m_{v_{i_b \rightarrow a}} \geq m_{v_{i_b}}$ (resp. $\leq$) pour une métrique à maximiser (resp. à minimiser), où $m_{v_{i_x \rightarrow y}}$ correspond à la métrique calculé pour l'étudiant x après lui avoir attribué l'affectation de l'étudiant y . On notera le prédicat $i_a \xleftrightarrow{(P, m_v)} i_b$ valant 0 s'il n'existe pas d'échange de Pareto entre le couple (i_a, i_b) pour la métrique vectorielle m_v et 1 sinon. On qualifiera de front de Pareto l'ensemble des solutions tels qu'aucun échanges de Pareto existe pour une métrique donnée.

Lorsqu'un échange de Pareto existe, alors nous savons que la solution n'est pas optimale (sauf en égalité stricte) pour la métrique désignée. Ainsi, pour atteindre une solution optimale respectivement à une métrique, il nous suffit de chercher les échanges de Pareto possibles et d'exécuter les échanges jusqu'à ce qu'il n'y en ai plus.

Métrique (Métriques d'échanges). À partir de l'observation précédente, il peut être intéressant de compter le nombre d'échange de Pareto pour une métrique vectorielle m_v désignée :

$$\#\text{ParetoSwap}(A_{i,j}) = \sum_{k=1}^{n-1} \sum_{l=k+1}^n i_k \xleftrightarrow{(P, m_v)} i_l$$

À noter que cette métrique est extrêmement dépendante des métriques vectorielles utilisées. En effet, la forme du front de Pareto dépend de la définition de celles-ci et de ce que l'on cherche à optimiser. Au niveau de l'interprétation, plus le nombre d'échange est bas, mieux la solution est optimisé ; à l'inverse, plus le nombre d'échange est élevé, moins la solution est bonne. Aussi, il peut être intéressant de diviser la valeur obtenu par le nombre d'échanges techniques dans l'affectation générale ; en effet, cela permet d'avoir un meilleur aperçu de l'optimisation de la solution dans de grandes instances où un grand nombre d'échange technique peut exister (sans pour autant être de Pareto).

3.6 Autre indicateurs, les tests d'hypothèses

Dans le cadre de nos évaluations, il peut également être important, en plus de regarder les métriques, de vérifier si les affectations proposées respectent un point important : « Y-a-t'il une façon permettant de prendre avantage de la méthode d'affectation à ses propres fins ? ». À des fins d'équités, nous devons éviter que cela soit le cas.

Les trois facteurs les plus importants à vérifier sont : **(1)** « Est-ce que l'ordre de remplissage du formulaire par les étudiants est déterminant pour avoir une meilleure affectation ? », **(2)** « Est-ce que le parcours des étudiants impacte la qualité des affectations ? » et bien sûr, en lien avec le biais de Type I, **(3)** « Est-ce que le nombre d'UEs choisies par les étudiants impacte la qualité de leurs affectations par rapport à d'autres ? ».

Dans l'idéal, l'affectation proposé vérifie que les trois proposition ci-dessus soit fausses. Pour cela, nous pourrions utiliser les tests d'hypothèses et plus particulièrement le test H de Kruskal-Wallis [2], suivi éventuellement du test U de Mann-Whitney [1].

Définition 7 (Test H de Kruskal-Wallis). Le test H de Kruskal-Wallis est un test statistique de comparaison non paramétrique de plusieurs groupes portant les hypothèses suivantes :

$$\begin{aligned} H_0 : & \quad \ll \text{La distribution des groupes se faisant comparés sont les mêmes.} \gg \\ H_1 : & \quad \ll \text{Au moins une distribution des groupes se faisant comparés est différente.} \gg \end{aligned}$$

Ce test nous est utile, car il nous permettrait dans un premier temps de vérifier si la distribution pour une certaine métrique vectorielle donnée (mesures) dépend d'un facteur extérieur (groupes comme le nombre d'UEs choisies, le parcours de l'étudiant, etc.). Un autre avantage non négligeable d'implémenter ce test est qu'il ne requiert pas de propriétés contraignantes dans notre cas : la normalité n'est pas assumé (ok), les mesures sont continues (ok), les mesures sont indépendantes entres-elles (nous pouvons l'assumer), les groupes sont indépendants (oui). Dans la mesure où il serait trop lourd de rédiger l'intégralité du fonctionnement du test, nous ne l'expliquerons pas ici. Concernant l'implémentation en Python, celle-ci est possible via la librairie Scipy et la commande `scipy.stats.kruskal` (`kruskal.test` en R).

Interprétation : Bien qu'un peu plus complexe que ça, nous simplifierons l'interprétation du test d'Hypothèse ainsi : « Si la p-value est inférieur à 5%, alors nous rejetons H_0 et concluons H_1 . ». Attention, si la p-value est au dessus du seuil critique 0.05, nous ne pouvons pas conclure en l'absence de différences entre les distributions, juste ne pas rejeter l'hypothèse pour l'instant.

Si l'on rejette H_0 sur le test H de Kruskal-Wallis, nous savons uniquement qu'une distribution est différente, mais pas laquelle. Il est donc important, s'il on souhaite enquêter plus en détail d'exécuter un test U de Mann-Whitney pour chacune des paires de groupe possible.

Définition 8 (Test U de Mann-Whitney). Le test U de Mann-Whitney est un test statistique de comparaison non paramétrique sur deux groupes portant les hypothèses suivantes :

$$\begin{aligned} H_0 : & \quad << \text{Les distributions X et Y sont égales en loi} >> \\ H_1 : & \quad << \text{X est stochastiquement supérieur à Y, ou } F_X < F_Y >> \end{aligned}$$

Plus simplement l'hypothèse alternative utilisée ici veut dire que la distribution de X a généralement de plus grande valeurs que celle de Y . Concernant les requis pour ce test, celui-ci ne requiert pas de normalité pour les distributions (ok), requiert que les valeurs étudiées soient continues (ok) et que les mesures soient indépendantes (chose que nous assumons). Pour les mêmes raisons que le test H de Kruskal-Wallis, nous n'allons pas détailler son fonctionnement, mais mentionner les implémentations en Python (`scipy.stats.mannwhitneyu`) et en R (`wilcox.test`). Les remarques sur l'interprétations sont également sensiblement identique que pour le test précédemment présenté.

En utilisant ces deux tests, nous sommes donc maintenant en mesure d'évaluer si une affectation est influencé par des facteurs non désirés.

4 Méthodologie et implémentation

4.1 Méthode proposée

4.2 Implémentation

À faire.

5 Expériences

À faire.

6 Résultats et discussions

6.1 Résultats

À faire.

6.2 Discussion

À faire.

7 Conclusion

À faire.

Références

- [1] Donald R. Whitney Henry B. Mann. On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 1947.
- [2] W. Allen Wallis William H. Kruskal. Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 1952.